دانشگاه تهران

پردیس دانشکده‌های فنی

دانشکده برق و کامپیوتر

درس مدل‌های مولد عمیق

مدرس: دکتر مصطفی توسلی‌پور

تمرین شماره ۴

دی ۱۴۰۴

فهرست مطالب

سوال اول: مدل‌های دیفیوژن ۳
بخش اول: سوالات تئوری ۴
سوال اول: اثبات فرم بسته ۴
سوال دوم: مزیت پیش‌بینی نویز ۴
سوال سوم: تحلیل تابع هزینه (VLB) ۴
سوال چهارم: نمونه‌برداری DDIM ۴
سوال پنجم: هدایت بدون دسته‌بند (CFG) ۴
بخش دوم: سوالات عملی ۵
زیربخش اول: مقدمه‌ای بر مدل‌های دیفیوژن (DDPM و DDIM) ۵
مرحله اول: پیاده‌سازی برنامه‌ریزی نویز (Variance Scheduler) ۵
مرحله دوم: پیاده‌سازی تابع perturb_input ۵
مرحله سوم: حلقه‌ی آموزش ۶
مرحله چهارم: پیاده‌سازی نمونه‌برداری (Sampling) ۶
زیربخش دوم: Stable Diffusion و تکنیک DreamBooth ۷
مرحله اول: آماده‌سازی داده‌ها ۸
مرحله دوم: تکمیل کلاس دیتاست ۸
مرحله سوم: تولید تصاویر کلاس (امتیازی) ۸
مرحله چهارم: حلقه‌ی آموزش ۸
مرحله پنجم: تست و استنتاج ۸

سوال دوم: فلو مچینگ و سری‌های زمانی ۹
بخش اول: سوالات تئوری ۱۰
سوال اول: میدان برداری ۱۰
سوال دوم: مسیرهای خطی ۱۰
سوال سوم: تابع زیان ۱۰
بخش دوم: سوالات عملی ۱۱
گزارش نتایج و ارزیابی مدل ۱۲
مرحله ۱: ثبت و بررسی تابع هزینه در طول آموزش ۱۲
مرحله ۲: رسم نمودار LOSS آموزش و آزمون ۱۲
مرحله ۳: تولید داده‌ی مصنوعی (SAMPLING) ۱۲
مرحله ۴: نمایش نمونه‌های سری زمانی تولیدشده ۱۲
مرحله ۵: مقایسه کیفی سری‌های زمانی واقعی و تولیدشده ۱۲

نکات تحویل ۱۴

سوال اول: مدل‌های دیفیوژن

مدل‌های Diffusion نسل جدیدی از مدل‌های مولد هستند که در سال‌های اخیر نقش مهمی در تولید تصویر، صدا و حتی متن ایفا کرده‌اند. ایده‌ی اصلی این مدل‌ها بسیار شهودی است: ما یک داده‌ی واقعی (مثل تصویر) را برداشته و در چندین گام متوالی به آن نویز گوسی اضافه می‌کنیم تا در نهایت به یک نویز تقریباً کاملاً گوسی برسیم. سپس مدلی را آموزش می‌دهیم تا این فرایند را برعکس کند؛ یعنی بتواند از روی داده‌ی نویزی، مقدار نویز افزوده شده را تخمین بزند و کم‌کم آن را حذف کند تا دوباره به داده‌ی معنادار برسد.

در این میان، مدل‌های DDPM (Denoising Diffusion Probabilistic Models) [۱] یکی از معروف‌ترین پیاده‌سازی‌های این ایده هستند که با تعریف یک زنجیره‌ی مارکوف رو به جلو (اضافه کردن نویز) و یک فرایند رو به عقب (حذف نویز) سعی می‌کنند توزیع داده‌های واقعی را مدل کنند. پس از آن مدل DDPM [۲] معرفی شد که با تغییر نحوه‌ی نمونه‌گیری در مسیر رو به عقب، امکانی برای تولید سریع‌تر نمونه‌ها و کنترل بیشتر روی فرایند ایجاد می‌کند.

بخش اول: سوالات تئوری

سوال اول: اثبات فرم بسته

در DDPM [۱]، فرایند اضافه کردن نویز به صورت زیر تعریف می‌شود:

$$q(x_t \mid x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t} x_{t-1}, (1-\alpha_t)I)$$

که در آن $\alpha_t = 1 - \beta_t$. نشان دهید که می‌توان این توزیع را برای هر نقطه در زمان به صورت زیر نوشت:

$$q(x_t \mid x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1-\bar{\alpha}_t)I)$$

که در آن $\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$ است. (۴ نمره)

سوال دوم: مزیت پیش‌بینی نویز

در DDPM معمولاً شبکه عصبی را طوری آموزش می‌دهیم که نویز ϵ در گام t را پیش‌بینی کند، نه اینکه مستقیماً میانگین $\mu_\theta(x_t, t)$ یا تصویر تمیز را خروجی دهد. دو مزیت پیش‌بینی ϵ را بنویسید. (۴ نمره)

سوال سوم: تحلیل تابع هزینه (VLB)

تابع هزینه DDPM از یک کران پایین وریشنالی (VLB) روی log likelihood داده‌ها به دست آورده می‌شود و به چند ترم KL و یک ترم بازسازی تجزیه می‌شود. در عمل معمولاً فقط با لاس ساده‌شده پیش‌بینی نویز (MSE) آموزش می‌دهند.

۱. الف) از نظر مفهومی، ترم‌های KL در این VLB چه چیزی را تشویق می‌کنند؟

۲. ب) چرا در عمل قابل قبول است که بیشتر این ترم‌ها را نادیده بگیریم و فقط با لاس MSE نویز را آموزش دهیم؟

(۴ نمره)

سوال چهارم: نمونه‌برداری DDIM

مدل DDIM (Denoising Diffusion Implicit Models) از همان مدل آموزش‌دیده DDPM استفاده می‌کند ولی فرایند معکوس را تغییر می‌دهد.

۱. الف) از نظر مفهومی، DDIM چگونه وقتی $\eta = 0$ باشد نمونه‌گیری را deterministic می‌کند؟

۲. ب) چرا DDIM معمولاً می‌تواند با تعداد گام‌های بسیار کمتر از DDPM نمونه‌های قابل قبول تولید کند؟

(۴ نمره)

سوال پنجم: هدایت بدون دسته‌بند (CFG)

مقاله Classifier-Free Diffusion Guidance [۳] را مطالعه کنید و به پرسش‌های زیر پاسخ دهید:

۱. الف) ایده اصلی این روش برای شرطی‌سازی (مثلاً بر روی متن یا برچسب کلاس) چیست و چرا به آن بدون دسته‌بند یا Classifier-Free گفته می‌شود؟

۲. ب) از نظر مفهومی توضیح دهید افزایش ضریب راهنمایی (guidance scale) چه اثری روی **کیفیت** و چه اثری روی **تنوع** نمونه‌های تولیدی دارد.

(۴ نمره)

بخش دوم: سوالات عملی

این بخش از تمرین به بررسی عمیق و پیاده‌سازی گام‌به‌گام مدل‌های دیفیوژن می‌پردازد. هدف از این بخش، درک تئوری و عملی نحوه کارکرد این مدل‌ها، از مفاهیم پایه تا تکنیک‌های پیشرفته مانند Fine-tuning است.
این بخش شامل دو زیربخش است:

۱. **زیربخش اول:** پیاده‌سازی مدل‌های پایه DDPM و DDIM.

۲. **زیربخش دوم:** کار با مدل‌های Latent Diffusion (Stable Diffusion) و تکنیک‌های DreamBooth و LoRA.

زیربخش اول: مقدمه‌ای بر مدل‌های دیفیوژن (DDPM و DDIM)

مدل‌های دیفیوژن احتمالی (Denoising Diffusion Probabilistic Models - DDPM) دسته‌ای از مدل‌های مولد هستند که با یادگیری معکوس کردن یک فرآیند انتشار نویز، داده‌های جدید تولید می‌کنند.

تئوری فرآیند مستقیم و معکوس

۱. **فرآیند مستقیم:** در این مرحله، به‌تدریج نویز گوسی به داده‌ی اصلی (مثلاً تصویر x_0) اضافه می‌شود تا زمانی که تصویر به نویز کامل x_T تبدیل شود. این فرآیند به صورت زنجیره مارکوف مدل‌سازی می‌شود.

۲. **فرآیند معکوس:** هدف مدل یادگیری این فرآیند است؛ یعنی چگونه از نویز خالص (x_T) شروع کرده و با حذف تدریجی نویز، به تصویر اولیه (x_0) برسیم. شبکه عصبی معمولاً (U-Net) در هر مرحله پیش‌بینی می‌کند که چه مقدار نویز باید حذف شود.

تفاوت DDPM و DDIM

- **DDPM:** فرآیند نمونه‌برداری در DDPM یک فرآیند تصادفی (Stochastic) و مارکوفی است. برای تولید یک تصویر با کیفیت، معمولاً نیاز به تعداد زیادی قدم زمانی (مثلاً ۱۰۰۰) است که باعث کندی تولید می‌شود.
- **DDIM (Denoising Diffusion Implicit Models):** این مدل‌ها فرآیند معکوس را به صورت قطعی و غیر مارکوفی فرمول‌بندی می‌کنند. این ویژگی اجازه می‌دهد تا با پرش از روی مراحل زمانی، فرآیند تولید را بسیار سریع‌تر کنیم (مثلاً در ۵۰ قدم به جای ۱۰۰۰ قدم) بدون افت محسوس کیفیت.

مرحله اول: پیاده‌سازی برنامه‌ریزی نویز (Variance Scheduler)

در سلول مربوطه، متغیر β_t را به صورت خطی (Linear Scheduler) مقداردهی کنید. مقادیر β_1 و β_2 در هایپرپارامترها داده شده است.

(۳ نمره)

مرحله دوم: پیاده‌سازی تابع perturb_input

- این تابع باید نویز را به تصویر اضافه کند. با استفاده از "Reparameterization Trick" اینکار را بایستی انجام دهید.
- کد مربوط به محاسبه x_t و نویز ϵ را تکمیل کنید.

(۴ نمره)

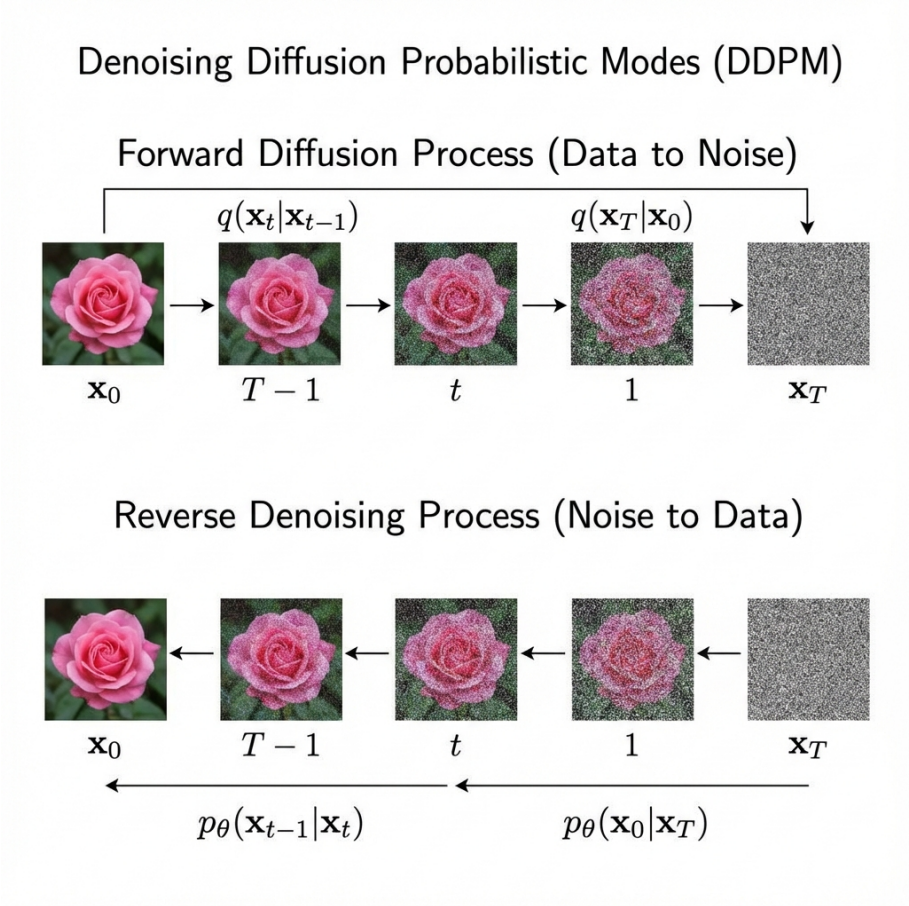

شکل ۱: دیاگرام فرآیند مستقیم و معکوس در مدل‌های دیفیوژن

مرحله سوم: حلقه‌ی آموزش

در حلقه‌ی آموزش، مراحل زیر را پیاده‌سازی کنید:

۱. یک دسته‌ی داده از دیتالودر بگیرید.

۲. یک قدم زمانی تصادفی t برای هر داده انتخاب کنید.

۳. با استفاده از perturb_input، تصویر نویزی و نویز واقعی را بدست آورید.

۴. مدل (شبکه عصبی) نویز را پیش‌بینی می‌کند.

۵. اختلاف بین نویز واقعی و نویز پیش‌بینی شده (Loss) را محاسبه و پس‌انتشار (Backpropagate) کنید.

(۴ نمره)

مرحله چهارم: پیاده‌سازی نمونه‌برداری (Sampling)

- الگوریتم نمونه‌برداری معکوس DDPM را پیاده‌سازی کنید.
- از نویز خالص شروع کنید و در یک حلقه از T تا ۱، در هر مرحله نویز را با استفاده از مدل حذف کنید تا به تصویر نهایی برسید.

(۴ نمره)

زیربخش دوم: Stable Diffusion و تکنیک DreamBooth

در این زیربخش با مدل‌های پیشرفته‌تر Latent Diffusion آشنا می‌شویم و یاد می‌گیرید چگونه یک مدل بزرگ را برای یک سوژه‌ی خاص آموزش دهید و فاین‌تیون کنید.

معماری Stable Diffusion

مدل Stable Diffusion [۴] برای کاهش هزینه محاسباتی، فرآیند دیفیوژن را در فضای نهان انجام می‌دهد، نه در فضای پیکسل. اجزای اصلی آن عبارتند از:

۱. **VAE (Variational Autoencoder):** تصویر را به فضای نهان می‌برد و برمی‌گرداند.

۲. **U-Net:** وظیفه حذف نویز در فضای نهان را دارد.

۳. **Text Encoder (CLIP):** متن ورودی را به بردار تبدیل می‌کند تا مدل بفهمد چه چیزی باید تولید کند.

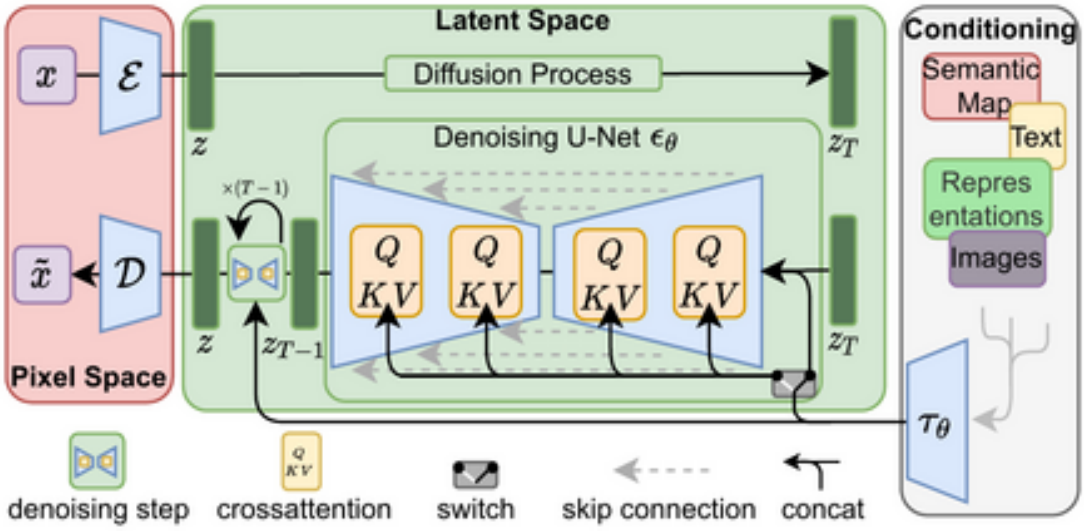

شکل ۲: دیاگرام معماری Stable Diffusion که شامل U-Net، VAE و Text Encoder است.

DreamBooth و LoRA

- **DreamBooth [۵]:** تکنیکی برای آموزش مدل با تعداد کمی عکس (۳-۵ عدد) از یک سوژه‌ی خاص (مثلاً سگ شما). برای اینکه مدل سوژه را یاد بگیرد، آن را به یک توکن خاص و نادر (مثل sks) متصل می‌کنیم (مثلاً "A photo of a sks dog").
- **Prior Preservation:** برای جلوگیری از فراموشی مدل (مثلاً فراموش نکند سگ‌های معمولی چه شکلی هستند)، همزمان با عکس‌های سوژه، عکس‌های عمومی تولید شده توسط خود مدل (Class Images) را نیز به مدل می‌دهیم.
- **LoRA [۶]:** برای فاین‌تیون کردن کل مدل‌هایی که بسیار سنگین هستند استفاده می‌شود. LoRA ماتریس وزن‌های مدل را فریز می‌کند و فقط ماتریس‌های کوچک و کم‌رتبه‌ای را به لایه‌ها اضافه می‌کند که قابل آموزش هستند. این کار حجم و سرعت آموزش را به شدت بهبود می‌بخشد.

مرحله اول: آماده‌سازی داده‌ها

- یک سوژه انتخاب کنید و ۵ تصویر از آن تهیه و در پوشه instance_data آپلود کنید.
- متغیرهای instance_prompt (مثلاً "a photo of a sks cat") و class_prompt (مثلاً "a photo of a cat") را تنظیم کنید.

(۲ نمره)

مرحله دوم: تکمیل کلاس دیتاست

- متد __getitem__ را کامل کنید.
- این متد باید هم تصاویر نمونه و هم تصاویر کلاس (در صورت فعال بودن Prior Preservation) را بارگزاری، تغییر اندازه و نرمال‌سازی کند. همچنین باید متن‌ها را توکن‌نایز کند.

(۶ نمره)

مرحله سوم: تولید تصاویر کلاس (امتیازی)

در بخش امتیازی، کدی بنویسید که با استفاده از مدل اولیه، تعدادی تصویر عمومی (مثلاً ۱۰۰ تصویر از سگ معمولی) تولید کرده و در پوشه class_data ذخیره کند.

مرحله چهارم: حلقه‌ی آموزش

داخل حلقه آموزش موارد زیر را پیاده‌سازی کنید:

۱. تولید نویز و اضافه کردن آن به Latentها (فرآیند مستقیم).

۲. پیش‌بینی نویز توسط مدل (U-Net).

۳. محاسبه Loss و آپدیت وزن‌های LoRA.

(۷ نمره)

مرحله پنجم: تست و استنتاج

- پس از آموزش، مدل را لود کنید.
- با پرامپت‌های مختلف (مثلاً "sks dog in a bucket"، "sks dog on the moon") و تنظیمات مختلف (guidance_scale) تصویر تولید کنید و نتایج را تحلیل کنید.

(۵ نمره)

سوال دوم: فلو مچینگ و سری‌های زمانی

در سال‌های اخیر، مدل‌های مولد پیوسته (Continuous Generative Models) به‌عنوان جایگزینی کارآمد برای مدل‌های دیفیوژن گسسته معرفی شده‌اند. یکی از رویکردهای مهم در این حوزه، Flow Matching است که با یادگیری مستقیم یک میدان برداری، فرآیند انتقال از یک توزیع ساده (مانند نویز گوسی) به توزیع داده‌های واقعی را مدل می‌کند.

هدف از این تمرین، آشنایی عمیق با مبانی نظری و عملی Flow Matching و بررسی توانایی این مدل‌ها در مدل‌سازی و تولید سری‌های زمانی مالی واقعی است. در این تمرین، Flow Matching برای یادگیری توزیع بازدهی‌های لگاریتمی (Log-Returns) بازار سهام مورد استفاده قرار می‌گیرد.

بخش اول: سوالات تئوری

سوال اول: میدان برداری

[۷] در مدل‌های Flow Matching، به‌جای تعریف یک فرآیند تصادفی رو به جلو و معکوس، یک میدان برداری زمان‌وابسته $v_\theta(x,t)$ آموزش داده می‌شود.

۱. **الف)** توضیح دهید این میدان برداری چه نقشی در انتقال نمونه‌ها از توزیع نویز به توزیع داده دارد؟

۲. **ب)** به‌صورت مفهومی Flow Matching را با Diffusion Models مقایسه کنید و مهم‌ترین تفاوت آن‌ها را بیان کنید. حالتی این دو مدل شبیه به هم عمل می‌کنند؟

(۱۰ نمره)

سوال دوم: مسیرهای خطی

در Flow Matching، داده‌ی میانی x_t معمولاً با استفاده از یک مسیر خطی بین نویز x_1 و داده‌ی واقعی x_0 ساخته می‌شود.

۱. **الف)** چرا استفاده از مسیرهای خطی در آموزش Flow Matching انتخاب مناسبی است؟ آیا همواره مسیرهای خطی مسیر بهینه است؟ چرا؟

۲. **ب)** این انتخاب چه تأثیری بر پایداری آموزش و سادگی تابع هزینه دارد؟

(۵ نمره)

سوال سوم: تابع زیان

در روش score matching هدف این است که تابع زیان بهینه شود، به‌طوری‌که این روش امکان یافتن مسیری را فراهم می‌کند که منجر به نزدیک‌شدن به توزیع داده‌های واقعی شود. به‌طور مشابه، در روش denoising score matching از تابع $\log p(x_t)$ به‌جای تابع امتیاز $\log q(x_t|x_0)$ استفاده می‌شود.

با فرض اینکه:

$$q(x_t|x_0) \sim \mathcal{N}(x_0, \sigma_t^2 I)$$

نشان دهید که تابع زیان به صورت زیر بازنویسی می‌شود:

$$E_{t,x_0\sim p_{data},\epsilon\sim\mathcal{N}(0,I)}\left[\left\|s_\theta(x_t,t) - \frac{x_0 - x_t}{\sigma_t^2}\right\|_2^2\right]$$

(۵ نمره)

بخش دوم: سوالات عملی

سری‌های زمانی نقش مهمی در حوزه‌هایی مانند اقتصاد، مالی، هواشناسی و سیستم‌های کنترلی دارند. داده‌های مالی به‌ویژه دارای ویژگی‌هایی مانند نویز بالا، همبستگی زمانی و نوسانات غیرایستا هستند که آن‌ها را به یک بستر چالش‌برانگیز و در عین حال مناسب برای ارزیابی مدل‌های مولد تبدیل می‌کند.

در این بخش، هدف استفاده از مدل Flow Matching برای یادگیری توزیع سری‌های زمانی مالی و تولید داده‌های مصنوعی واقع‌گرایانه است.

معرفی داده‌های سری زمانی

در این تمرین از داده‌های واقعی بازار سهام برای آموزش و ارزیابی مدل Flow Matching استفاده می‌شود. داده‌ها مربوط به نماد مالی SPY (S&P 500 ETF) بوده و بازه‌ی زمانی آن از ۱ ژانویه ۲۰۱۰ تا ۳۱ دسامبر ۲۰۲۳ را پوشش می‌دهد. داده‌ی خام شامل قیمت پایانی تعدیل‌شده است که پس از حذف مقادیر گمشده، به بازدهی‌های لگاریتمی (Log-Returns) تبدیل می‌شود. استفاده از بازدهی لگاریتمی باعث حذف روند قیمتی و مناسب‌تر شدن داده‌ها برای مدل‌سازی آماری و یادگیری ماشین می‌گردد.

برای آماده‌سازی داده‌ها، سری زمانی بازدهی لگاریتمی به توالی‌های هم‌پوشان با طول ثابت ۶۴ تبدیل می‌شود تا هر نمونه نمایانگر رفتار بازار در یک بازه‌ی زمانی کوتاه باشد. سپس داده‌ها به‌صورت سراسری استانداردسازی می‌شوند تا پایداری آموزش مدل تضمین گردد. در نهایت، دیتاست به‌صورت ترتیبی (Chronological Split) به دو بخش مجزا تقسیم می‌شود؛ به‌طوری که ۹۰٪ ابتدایی داده‌ها برای آموزش و ۱۰٪ انتهایی داده‌ها برای آزمون در نظر گرفته می‌شوند. استفاده از داده‌های آزمون در فرآیند آموزش یا تنظیم مدل مجاز نیست و صرفاً برای ارزیابی عملکرد نهایی مدل به‌کار می‌رود.

نکات پیاده‌سازی

در پیاده‌سازی این تمرین، باید از یک مدل Flow Matching مبتنی بر شبکه عصبی استفاده کنید که وظیفه آن پیش‌بینی میدان برداری زمان‌وابسته است. ورودی مدل شامل داده‌ی میانی x_t به‌همراه مقدار زمان t بوده و خروجی آن برداری است که جهت و شدت حرکت نمونه در فضای داده را مشخص می‌کند. نویز اولیه از یک توزیع گاوسی استاندارد $\mathcal{N}(۰, I)$ نمونه‌گیری می‌شود و مقادیر زمانی مورد استفاده در آموزش نیز به‌صورت یکنواخت از بازه $[۰, ۱]$ انتخاب می‌گردند.

هایپرپارامترهای پیشنهادی:

Hyperparameter	Value
Optimizer	Adam
Batch Size	512
Learning Rate	2e-4
Epoch	100

جدول ۱: جدول هایپرپارامترهای پیشنهادی برای آموزش مدل

گزارش نتایج و ارزیابی مدل

در این بخش، نتایج آموزش، تولید داده و ارزیابی مدل Flow Matching را به‌صورت مرحله‌به‌مرحله گزارش و تحلیل نمایید. تمامی مراحل زیر باید به‌صورت کامل انجام شده و تحلیل مربوط به هر بخش در گزارش نهایی ارائه گردد.
(۳۰ نمره)

مرحله ۱: ثبت و بررسی تابع هزینه در طول آموزش

در طول فرآیند آموزش مدل، مقدار تابع هزینه (Loss) را در هر epoch یا step ذخیره کنید. این مقادیر باید برای داده‌های آموزش ثبت شوند و مقدار Loss روی داده‌های آزمون نیز در بازه‌های مشخص محاسبه و ذخیره گردد.
(۱ نمره)

مرحله ۲: رسم نمودار LOSS آموزش و آزمون

نمودارها را به‌گونه‌ای نمایش دهید که امکان مقایسه بین Loss آموزش و آزمون فراهم باشد.

- آیا اختلاف قابل‌توجهی بین Loss آموزش و آزمون وجود دارد؟
- در صورت مشاهده اختلاف زیاد، احتمال overfitting یا underfitting را تحلیل کرده و دلایل احتمالی آن را بیان کنید.

(۳ نمره)

مرحله ۳: تولید داده‌ی مصنوعی (SAMPLING)

پس از اتمام آموزش، با استفاده از میدان برداری آموزش‌دیده، فرآیند تولید داده را پیاده‌سازی کنید. برای این کار باید از نویز گاوسی استاندارد شروع کرده و با حل عددی معادله:

$$\frac{dx}{dt} = v_\theta(x, t) \tag{۱}$$

در بازه زمانی $t \in [۰, ۱]$، سری‌های زمانی مصنوعی تولید نمایید. در توضیح دهید تعداد گام‌های حل‌گر چه اثری بر کیفیت داده‌های تولیدشده و هزینه محاسباتی دارد.
توجه: می‌توانید از کتابخانه‌های آماده برای این حل‌گرها استفاده کنید. در صورت استفاده روش کار این حل‌گرها را توضیح دهید.

(۱۵ نمره)

مرحله ۴: نمایش نمونه‌های سری زمانی تولیدشده

چند نمونه از سری‌های زمانی تولیدشده را رسم کنید. در صورت امکان، هم نسخه نرمال‌شده و هم نسخه بازگردانی‌شده به مقیاس اصلی (Denormalized) را نمایش دهید. بررسی کنید آیا دامنه، نوسان و شکل کلی سری‌های زمانی تولیدشده با داده‌های واقعی سازگار است یا خیر.

(۳ نمره)

مرحله ۵: مقایسه کیفی سری‌های زمانی واقعی و تولیدشده

چند نمونه از سری‌های زمانی واقعی (از مجموعه آزمون) را در کنار سری‌های زمانی تولیدشده رسم کنید. به‌صورت کیفی توضیح دهید مدل تا چه حد توانسته الگوهای کلی سری زمانی را حفظ کند و آیا در بازتولید رفتارهای خاص (مانند جهش‌ها یا تغییرات شدید) ضعف دارد یا خیر؟

(۳ نمره)

مرحله ۶: مقایسه توزیع داده‌های واقعی و تولیدشده

توزیع مقادیر بازدهی لگاریتمی (Log-Returns) در داده‌های واقعی و داده‌های تولیدشده را با استفاده از Histogram یا KDE رسم کرده و تحلیل خود را ارائه دهید.

(۱۰ نمره)

مرحله ۷: ارزیابی آماری پایه و نوسانات

برای داده‌های واقعی و تولیدشده، معیارهای زیر را محاسبه و گزارش کنید:

- میانگین (Mean)
- واریانس (Variance)
- نوسان (Volatility)

نتایج به‌دست‌آمده را مقایسه کرده و توضیح دهید آیا مدل شدت نوساناتبازار را به‌درستی بازتولید کرده است یا خیر؟
(۵ نمره)

مرحله ۸: ارزیابی پیشرفته ساختار توزیعی و زمانی

در این مرحله باید از معیارهای زیر استفاده شود:

۱. **الف) Sliced Wasserstein Distance (SWD)**

۲. **ب) Autocorrelation Mean و Autocorrelation MSE**

آیا مدل علاوه بر شباهت توزیعی، توانسته وابستگی‌های زمانی را نیز به‌درستی یاد بگیرد؟ تحلیل خود را برای هر یک از این معیارها ارائه دهید. هر یک از این معیارها چه چیز را اندازه‌گیری می‌کنند؟

(۱۰ نمره)

نکات تحویل

- مهلت ارسال این تمرین تا پایان روز **شنبه ۲۷ دی** خواهد بود.
- این زمان قابل تمدید نیست و در صورت نیاز می‌توانید از grace time استفاده کنید.
- در نظر داشته باشید که حداکثر مهلت آپلود تمرین در سامانه تا ۷ روز پس از مهلت تحویل است و پس از آن سامانه بسته خواهد شد.
- پیاده‌سازی باید با زبان برنامه‌نویسی پایتون باشد و کدهای شما باید قابل اجرا بوده و به همراه گزارش آپلود شوند.
- انجام این تمرین به صورت **یک‌نفره** می‌باشد.
- در صورت مشاهده هر گونه تشابه در گزارش کار یا کدهای پیاده‌سازی، این امر به منزله تقلب برای طرفین در نظر گرفته خواهد شد.
- استفاده از کدهای آماده بدون ذکر منبع و بدون تغییر به منزله تقلب خواهد بود و نمره تمرین شما صفر در نظر گرفته می‌شود.
- در صورت رعایت نکردن فرمت گزارش کار، نمره گزارش به شما تعلق نخواهد گرفت.
- تحویل تمرین به صورت دست‌نویس قابل پذیرش نیست.
- تمامی تصاویر و جداول مورد استفاده در گزارش کار باید دارای توضیح (Caption) و شماره باشند.
- بخش زیادی از نمره شما مربوط به گزارش کار و روند حل مسئله است.

نحوه ارسال:
لطفاً فایل‌ها را با فرمت زیر نام‌گذاری و آپلود کنید:

HW4_[Lastname]_[StudentNumber].zip

ارتباط با دستیاران آموزشی:
در صورت وجود سوال یا ابهام می‌توانید از طریق ایمیل‌های زیر با موضوع DGM_HW4 در ارتباط باشید:

سوال اول: mollahoseini@ut.ac.ir
سوال دوم: fatemehnadir@gmail.com

با آرزوی سلامتی و موفقیت روزافزون

References

[1] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

[2] J. Song, C. Meng, and S. Ermon, "Denoising diffusion implicit models," in *International Conference on Learning Representations (ICLR)*, 2021.

[3] J. Ho and T. Salimans, "Classifier-free diffusion guidance," *arXiv preprint arXiv:2207.12598*, 2022.

[4] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-resolution image synthesis with latent diffusion models," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.

[5] N. Ruiz, Y. Li, V. Jampani, Y. Pritch, M. Rubinstein, and K. Aberman, "Dreambooth: Fine tuning text-to-image diffusion models for subject-driven generation," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023.

[6] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "Lora: Low-rank adaptation of large language models," in *International Conference on Learning Representations (ICLR)*, 2021.

[7] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, and M. Le, "Flow matching for generative modeling," in *International Conference on Learning Representations (ICLR)*, 2023.